

Desafio técnico — Agente LangChain / LangGraph

Prazo: 3 a 5 dias corridos a partir do recebimento deste enunciado

Formato: entrega em repositório Git + apresentação online (45–60 min)

Objetivo

Construa um agente de IA (LangChain ou LangGraph) que atenda a um destes cenários (escolha livre):

- um processo interno de uma empresa (ex.: suporte a colaboradores, operação, backoffice); ou
- o auxílio a colaboradores em alguma atividade do dia a dia; ou
- o atendimento a um consumidor em alguma necessidade ligada a um produto ou serviço.

O agente deve consumir uma fonte de dados, à sua escolha:

- A) base de conhecimento (RAG — documentos locais ou corpus público pequeno); ou
- B) API HTTP (tools / function calling — API pública ou mock no próprio repositório).

Não se preocupe com produtos ou arquitetura interna da nossa empresa. Use as práticas que você considera adequadas para um agente de IA.

Requisitos

1. Agente implementado com LangChain ou LangGraph.
2. Respostas em português.
3. Interação via CLI ou endpoint HTTP.
4. Comportamento claro quando o agente não souber responder ou quando a fonte falhar.
5. Se optar por RAG: indicar fonte/trecho usado. Se optar por API: indicar o que foi consultado (ex.: recurso ou campo).
6. Latência: medir ponta a ponta (pergunta → resposta completa); reportar p50 e p95 (ou equivalente) em um conjunto de pelo menos 20 perguntas representativas; indicar gargalos e o que foi feito para reduzir latência.
7. Escalabilidade: explicar o comportamento sob mais usuários/carga e incluir pelo menos uma evidência numérica alinhada à sua abordagem.

Entregáveis

Repositório Git sem secrets commitados (use variáveis de ambiente e um `.env.example`):

1. Código reproduzível.
 2. `README.md` — como configurar, como executar, como medir latência, como evidenciar escala, qual cenário e fonte (A ou B) você escolheu e por quê.
 3. `ARCHITECTURE.md` (ou seção equivalente no `README`) — fluxo do agente, principais trade-offs e o que mudaria sob mais carga, falhas de rede ou custo de LLM.
 4. Evidência de latência (tabela, CSV ou equivalente + resumo).
 5. Evidência de escala (números + interpretação breve).
 6. Roteiro de demonstração com 5 a 10 perguntas e o resultado esperado (mesmo que aproximado).
-

Apresentação

Na call você deverá:

1. Contextualizar o problema e a escolha de cenário/fonte.
 2. Mostrar a arquitetura e fazer demo ao vivo com 2–3 perguntas.
 3. Discutir latência e escala com base nos números entregues.
 4. Responder perguntas do time.
 5. Apresentar recursos de IA que utiliza para acelerar seu trabalho de desenvolvimento.
-

Defesa

Inclua ainda uma página de ADR:

Se este agente precisasse atender dezenas de usuários concorrentes em produção, como você separaria responsabilidades? Quais riscos identifica na implementação e possíveis meios de mitigá-los?